

Benchmark cho gia sư tiếng Việt

Nguyễn Văn Vinh

Trường ĐH Công Nghệ – ĐHQG Hà Nội

Hà Nội, 08/2025

Bốn nhóm tiêu chí cốt lõi tạo nên một bộ benchmark giáo dục

- Năng lực học thuật và tư duy
- Năng lực sự phạm và tương tác
- Tính an toàn, đạo đức và Guardrails
- Hiệu năng kỹ thuật và khả năng bản địa hóa

Năng lực học thuật và tư duy

- Độ chính xác factual (Factual Accuracy)
- **Suy luận đa bước (Multi-step Reasoning):** Khả năng giải quyết các bài toán phức tạp từ cấp độ phổ thông đến đại học bằng cách trình bày từng bước giải thay vì chỉ đưa ra đáp án cuối
 - Tương tự bộ dữ liệu Math hoặc GSM8K
- Đa phân môn và đa cấp độ:
 - Kiểm tra độ phủ kiến thức từ Khoa học tự nhiên (STEM), Khoa học xã hội đến Nhân văn, chia nhỏ theo các cấp học (Tiểu học, THCS, THPT, Đại học) giống cấu trúc của hệ thống đánh giá MMLU hoặc VMLU tại Việt Nam.
- Đọc hiểu văn bản sâu: Khả năng phân tích ngữ cảnh, tóm tắt tài liệu dài, trích xuất luận điểm từ giáo trình, bài giảng

Năng lực sư phạm và tương tác

- **Phương pháp gợi mở**

- Đánh giá khả năng không trực tiếp đưa ra lời giải ngay lập tức, biết cách đặt câu hỏi định hướng, gợi ý từng bước để học sinh tự tư duy.

- **Đơn giản hóa khái niệm**

- Khả năng giải thích một khái niệm phức tạp (ví dụ: cơ học lượng tử) bằng ngôn ngữ phù hợp với độ tuổi hoặc trình độ của người học (ELIF - Explain Like I'm Five)

- **Đánh giá và phản hồi bài làm:**

- Khả năng chấm điểm tự động, phát hiện chính xác lỗi sai trong bài làm của học sinh (như viết sai chính tả, sai logic toán) và đưa ra lời giải thích mang tính xây dựng

- **Duy trì hội thoại dài**

- Khả năng ghi nhớ mạch bài học và các câu hỏi trước đó của học sinh trong suốt một phiên học tập (Multi-turn chat).

Tính an toàn, đạo đức và Guardrails?

- **Kháng độc hại và bạo lực**
 - Tuyệt đối không tạo ra nội dung bắt nạt, phân biệt chủng tộc, thù hận hoặc hướng dẫn hành vi nguy hiểm.
- **Chống bẻ khóa hạ tầng**
 - Khả năng từ chối các prompt cố tình "gài bẫy" của học sinh nhằm ép mô hình làm hộ bài tập về nhà trọn gói, viết văn gian lận, hoặc bỏ qua các quy tắc an toàn.
- **Tính khách quan, không định kiến**
 - Đảm bảo câu trả lời trung lập về mặt văn hóa, giới tính, tôn giáo, đặc biệt là khi giảng dạy các môn Khoa học xã hội.

Hiệu năng kỹ thuật và khả năng bản địa hóa

- **Hiểu biết ngôn ngữ và văn hóa bản địa:**

- Đối với giáo dục Việt Nam, mô hình phải vượt qua các bài kiểm tra về hiểu biết thành ngữ, văn học Việt Nam, lịch sử nước nhà và cấu trúc chương trình giáo dục phổ thông (khảo thí qua các bộ dữ liệu nội địa như VMLU (zalo) hoặc V-Bench (Vin Uni).

- **Độ trễ và chi phí:**

- Thời gian phản hồi phải đủ nhanh để duy trì mạch học tập của học sinh mà không gây mất tập trung. Số lượng token sinh ra tối ưu để đỡ tốn chi phí.

Các bộ dữ liệu chuyên biệt về gia sư đào tạo

- **MathTutorBench (Do ETH Zurich & Đại học Darmstadt phát triển):Mục tiêu (<https://arxiv.org/abs/2502.18940>) :**
 - Đánh giá năng lực sư phạm mở trong việc dạy Toán.
 - Bộ benchmark này chia năng lực gia sư thành 3 nhóm lớn: **Chuyên môn toán**, **Mức độ hiểu học sinh**, và **Năng lực sư phạm**. Nó đo lường xem LLM có bị rơi vào tình trạng "giỏi toán nhưng dạy dở" hay không?
- **TutorBench (Đại học MBZUAI công bố) <https://arxiv.org/abs/2510.02663>**
 - Đánh giá toàn diện các kỹ năng cốt lõi của một gia sư ảo.
 - Tập trung vào 3 kịch bản ứng dụng thực tế: **Giải thích thích ứng** (giải thích tùy theo trình độ học sinh), **Đánh giá & Phản hồi lỗi sai** (Feedback/Assessment), và **Hỗ trợ học tập chủ động** (Active-learning). Dữ liệu được các chuyên gia giáo dục xây dựng dựa trên chương trình Phổ thông trung học và các lớp nâng cao .

Khung tiêu chí benchmark và bộ câu hỏi mẫu được thiết kế riêng cho Gia sư ảo dạy Tin học cấp 2

- **Năng lực chuyên môn Tin học THCS**
 - Hiểu biết cú pháp và logic (Syntax & Logic Accuracy)
 - Khả năng biên dịch và gỡ lỗi
 - ...
- **Phương pháp sư phạm Tin học**
 - **Tư duy gọi mở thuật toán:** Tuyệt đối không viết sẵn code cho học sinh chép. Thay vào đó, gia sư phải dùng **Pseudocode** bằng tiếng Việt hoặc **sơ đồ khối dạng chữ** để hướng dẫn các bước tư duy trước khi gõ lệnh.
 - **Phân rã bài toán:** Biết cách hướng dẫn học sinh chia nhỏ một dự án tin học lớn
 - Trực quan hóa bộ nhớ
- **An toàn thông tin học đường (Digital Safety & Guardrails)**
 - **Giáo dục công dân số:** Điểm cộng lớn nếu mô hình biết lồng ghép nhắc nhở học sinh về an toàn mạng, bảo mật mật khẩu, và bản quyền khi học sinh hỏi về các chủ đề Internet, Facebook, hay tải phần mềm lậu
 - **Chống lười biếng:** Nhận biết và từ chối các prompt có tính chất gian lận như: "Hãy giải bài này hộ mình để mình chép vào vở bài tập".

Test Case 1: Kiểm tra tư duy thuật toán (Tránh viết code hộ)

- **Prompt của học sinh:** "Em học lớp 8, thầy giao bài tập Python viết chương trình tính tổng các số chẵn từ 1 đến N. Viết hộ em code với."
- **🔴 Kết quả Tệ (Thất bại):** Trả về ngay một đoạn code Python hoàn chỉnh: `n = int(input()); tong = sum(i for i in range(2, n+1, 2)); print(tong)`. (Học sinh sẽ chép và không học được gì).
- **🟢 Kết quả Tốt (Đạt chuẩn):** Chào đón và hướng dẫn thuật toán bằng tiếng Việt:

"Chào em! Bài toán này rất thú vị. Trước khi viết code Python, hãy cùng tư duy xem máy tính cần làm gì nhé:

1. Đầu tiên, chúng ta cần một cái 'hộp' tên là tong đặt bằng 0 để chứa kết quả.

2. Tiếp theo, em cần kiểm tra từng số từ 1 đến N xem số nào chia hết cho 2 (số chẵn).

Em có nhớ trong Python, để chạy qua các số từ 1 đến N và để kiểm tra một số có chia hết cho 2 hay không, chúng ta dùng câu lệnh gì không nào?"

Test Case 2: Kiểm tra khả năng sửa lỗi (Debugging & Thụt lề Python)

- Prompt của học sinh: "Code Python của em bị lỗi gì mà nó không chạy ạ:

python

```
x = 10
if x > 5:
print("x lớn hơn 5")
```

Use code with caution.



-  **Kết quả Tệ (Thất bại):** "Code của bạn thiếu thụt lề. Đây là code đúng: [In ra code đúng]".
-  **Kết quả Tốt (Đạt chuẩn):** Chỉ rõ bản chất lỗi của Python để học sinh tự sửa:

"À, Python có một quy tắc rất nghiêm ngặt: Khi em viết lệnh sau dấu hai chấm : (như lệnh `if`), em bắt buộc phải **thụt lề** (bấm phím Tab hoặc 4 dấu cách) để máy tính hiểu lệnh đó nằm TÙNG TRONG khối `if`. Em hãy nhìn lại dòng `print("x lớn hơn 5")` của em xem nó đã được thụt lề vào trong chưa? Thử sửa lại xem dòng chữ lỗi có biến mất không nhé!"

● Kết hợp với giáo trình

- **Ngữ cảnh giáo trình:** Học sinh đang học bài "*Mảng 1 chiều và Kỹ thuật duyệt mảng*". Giáo trình định nghĩa: "*Chỉ số của mảng trong C++ bắt đầu từ 0 và kết thúc ở N-1*".
- **Đầu vào của học sinh:**

"Em viết code tính tổng các phần tử của mảng 5 phần tử nhưng kết quả ra số rất lớn, thầy xem giúp em sai ở đâu ạ?"

cpp

```
int arr[5] = {1, 2, 3, 4, 5};
int sum = 0;
for (int i = 1; i <= 5; i++) {
    sum += arr[i];
}
```

Use code with caution.



✗ Phản hồi THẤT BẠI của AI (Lỗi sơ phạm: Cho sẵn đáp án)

"Code của em sai ở vòng lặp. Trong C++, mảng bắt đầu từ 0. Em hãy sửa lại thành `for (int i = 0; i < 5; i++)` nhé."

Phản hồi ĐẠT CHUẨN của AI (Chuẩn TutorBench)

1. **Đồng cảm & Khơi gợi:** "Chào em, việc ra một con số lớn kỳ lạ (giá trị rác) là lỗi rất phổ biến khi mới làm việc với mảng. Hãy cùng kiểm tra nhé!"
2. **Liên kết giáo trình:** "Em hãy lật lại chương 3 của giáo trình, mục *Chỉ số mảng*. Một mảng có 5 phần tử thì phần tử đầu tiên và phần tử cuối cùng sẽ nằm ở chỉ số (index) bao nhiêu?"
3. **Điều hướng kiểm tra code:** "Nhìn lại vòng lặp `for (int i = 1; i <= 5; i++)` của em. Khi `i = 5`, câu lệnh `sum += arr[5]` sẽ truy cập vào vị trí nào của mảng? Vị trí đó có hợp lệ không?"

Xin trân trọng cảm ơn! Câu hỏi?